



T.C.

GAZİOSMANPAŞA ÜNİVERSİTESİ

MÜHENDİSLİK VE MİMARLIK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ YÜKSEK LİSANS PROGRAMI

Evrişimsel Sinir Ağları

Final Ödevi

Hazırlayan

Emirhan AYDIN

229120660

1. Giriş

Deri kanseri, dünya genelinde en yaygın kanser türlerinden biri olup, erken teşhis ve tedavi ile hayatta kalma oranları önemli ölçüde artırılabilir. Ancak, deri kanserinin çeşitli türlerinin benzer klinik özellikler göstermesi, doğru teşhisi zorlaştırmaktadır. Bu bağlamda, derin öğrenme teknikleri, özellikle evrişimli sinir ağları (CNN), deri lezyonlarını sınıflandırmada umut verici sonuçlar vermektedir. Bu çalışmada, ISIC 2019 veriseti kullanılarak dört farklı deri kanseri türünü (bazal hücreli karsinom (BCC), benign keratoz lezyonları (BKL), malign melanom (MEL) ve nevüs (NV)) tahmin etmek amacıyla bir derin öğrenme modeli geliştirildi.

ISIC 2019 veriseti, toplamda 25,331 görüntüye ve dokuz farklı deri lezyonu sınıfına sahiptir. Ancak, her sınıfta yeterli sayıda görüntü bulunmamaktadır. Bu sınırlama nedeniyle çalışmamızda, her bir sınıf için yeterli sayıda örneğe sahip dört sınıfa odaklanıldı. Seçilen dört sınıfın her biri için eğitim setinde 1650, test setinde 250 ve doğrulama setinde 100'er görüntü kullanıldı. Bu şekilde, dengeli ve yeterince büyük bir veri seti elde edilerek modelin performansı artırılmaya çalışıldı.

İlk adım olarak, ISIC 2019 veriseti içindeki görüntüler belirlenen dört sınıfa göre ayrıldı ve eğitim, test ve doğrulama setlerine dağıtıldı. Veri setinin boyutunu artırmak ve modelin genelleme yeteneğini geliştirmek için veri genişletme (data augmentation) teknikleri kullanıldı. Daha sonra, TensorFlow-Keras kütüphanesi kullanılarak bir CNN modeli tasarlandı ve eğitildi. Modelin performansını optimize etmek amacıyla hiperparametreler ve CNN katmanlarının yapılandırılmaları değiştirildi.


Bu çalışmada, geliştirilen CNN modelinin başarımını değerlendirmek için, ISIC 2019 veri seti ile daha önce yapılmış çalışmalar incelendi ve kendi modelimizin sonuçları ile karşılaştırıldı. Bu sayede, modelimizin etkinliği ve doğruluğu hakkında kapsamlı bir değerlendirme yapıldı.

Sonuç olarak, bu çalışmanın amacı, deri kanseri teşhisinde kullanılabilecek etkili bir derin öğrenme modeli geliştirmek ve elde edilen sonuçları literatürdeki mevcut çalışmalarla karşılaştırarak modelin gücünü ve sınırlılıklarını ortaya koymaktır.

2. Benzer Çalışmalar


Literatürde, ISIC 2019 veri seti üzerinde yapılan çalışmalardan biri, çeşitli CNN modellerini kullanarak deri lezyonlarını sınıflandırmayı hedeflemiştir. Toplamda 8 hastalık sınıfı dahil edilen bu çalışmada kullanılan model, Soft Attention mekanizması ile zenginleştirilmiş bir CNN mimarisine dayanmaktadır. Modelin temel yapısı, convolution, max pooling, attention ve fully connected layerlardan oluşmaktadır. Model, eğitim sırasında veri çoğaltma (data augmentation) teknikleri kullanarak eğitim verilerini artırmakta ve modelin genelleme yeteneğini geliştirmektedir. Ayrıca modelde batch normalization ve dropout gibi yöntemler de kullanılmıştır.

Bu çalışmada geliştirilen model, ISIC 2019 veri setinin tamamı kullanılarak eğitilmiştir. Eğitim sonucunda, modelin doğruluk oranı %12.5 olarak rapor edilmiştir, bu da modelin performansının optimize edilmesi gerektiğini göstermektedir. Bu düşük doğruluk oranı, veri setinin zorluk derecesini ve sınıflar arası dengesizliği yansıtabilir.



Resim 1: Benzer Çalışmanın Accuracy ve Loss Grafiği (3)

Yapılan çalışmanın doğruluk (accuracy) ve kayıp (loss) grafiği Resim 1'de görüldüğü üzere geliştirilen modelin yetersiz olduğunu göstermektedir. Bunun birçok sebebi olabilir.



Resim 2: Benzer Çalışmanın Konfüzyon Matrisi (3)

Konfüzyon matrisi incelendiğinde geliştirilen CNN modelinin hastalıkları doğru olarak ayırt edemediği görülmektedir. Bu, veri setindeki dengesizlik, modelin yeterince derin veya basit olmaması, hiperparametrelerin doğru seçilmemesi, farklı hastalık görüntülerinin birbirinden ayırt edilemeyecek kadar benzer olması gibi nedenlerden kaynaklanabilir.

Çalışmamızda, bu belirtilen sebepler üzerinde durup problemin çözümüne bu durumlar üzerinde değişiklik yaparak ulaşmayı hedefledik. Buna istinaden, çalışmamız aynı veri seti üzerinde dört belirli sınıfa odaklanarak daha yüksek bir doğruluk oranı elde etmeyi amaçlamaktadır. Seçilen sınıflar, her biri için yeterli sayıda görüntü içermektedir (her sınıf için 1650 eğitim, 250 test ve 100 doğrulama görüntüsü). Bu, veri setinin dengeli olmasını sağlayarak modelin performansını artırmayı hedeflemektedir. Ayrıca, data augmentation teknikleri kullanılarak eğitim verilerinin çeşitliliği artırılacaktır.

Sonuç olarak, önceki çalışmaların sonuçlarına dayanarak, dört sınıfa odaklanmanın ve data augmentation tekniklerini kullanmanın modelin doğruluk oranını önemli ölçüde artırması beklenmektedir. Bu çalışma, mevcut literatürdeki bulgulara katkıda bulunarak deri kanseri teşhisinde daha etkili ve güvenilir bir derin öğrenme modeli geliştirmeyi amaçlamaktadır.

3. Yöntem

Bu çalışmanın amacı, ISIC 2019 veri setinde bulunan dört deri kanseri sınıfını (BCC, BKL, MEL ve NV) sınıflandıracak en optimum derin öğrenme modelini geliştirmektir. Bu hedefe ulaşmak için, modelin hiperparametreleri ve mimarisi değiştirilerek en uygun sonuçların elde edilmesi sağlanacaktır. Ayrıca, modelin performansını artırmak amacıyla çeşitli teknikler ve yöntemler kullanılmıştır.

Veri Hazırlığı

ISIC 2019 veri seti, toplamda 25,331 görüntü ve dokuz farklı sınıf içermektedir. Ancak, her sınıfta yeterli sayıda görüntü bulunmadığından, bu çalışmada dört sınıfa odaklanılacaktır. Seçilen sınıfların her biri için eğitim setinde 1650'şer görüntü, test ve doğrulama setlerinde ise 250 ve 100'er görüntü kullanılacaktır. Veri seti, eğitim, test ve doğrulama setlerine dengeli bir şekilde dağıtılarak modelin performansının artırılması hedeflenmiştir.

Veri Genişletme (Data Augmentation)

Veri setinin boyutunu artırmak ve modelin genelleme yeteneğini geliştirmek için veri genişletme (data augmentation) teknikleri kullanılacaktır. Bu teknikler arasında görüntü döndürme, yatay ve dikey çevirme, yakınlaştırma, parlaklık ve kontrast ayarlamaları gibi yöntemler yer alacaktır. Bu sayede, modelin farklı varyasyonları öğrenmesi sağlanarak daha iyi bir performans elde edilmesi amaçlanmaktadır.

Model Mimarisi

Modelin temel yapısı, convolutional katmanlar, max pooling katmanları, batch normalization ve dropout katmanlarından oluşacaktır. Convolutional katmanlar, görüntülerin özelliklerini çıkarırken, max pooling katmanları bu özelliklerin boyutunu azaltacaktır. Batch normalization, her bir mini-batch'in çıktısını normalleştirerek modelin öğrenme sürecini hızlandıracaktır. Dropout katmanları ise aşırı öğrenmeyi (overfitting) önlemek amacıyla bazı nöronları rastgele devre dışı bırakacaktır.

Hiperparametre Optimizasyonu

Modelin performansını optimize etmek için çeşitli hiperparametreler denenecektir. Bu hiperparametreler arasında öğrenme oranı, batch boyutu, katman sayısı, her katmandaki nöron sayısı ve dropout oranı gibi parametreler bulunmaktadır. Hiperparametrelerin en uygun kombinasyonunu belirlemek amacıyla rastgele arama (random search) veya grid arama (grid search) yöntemleri kullanılacaktır.

Callback

Callback'ler, model eğitimi sırasında belirli noktalarda veya koşullara bağlı olarak çağrılan işlevlerdir. Bu işlevler, modelin eğitim sürecini kontrol etmek ve özelleştirmek için kullanılır.

Bu çalışmada, modelin en başarılı olduğu hali tespit etmek ve model öğreniminin yavaşlamasını engellemek amacıyla ReduceLROnPlateau ve Checkpoint callback'leri kullanılacaktır.

ReduceLROnPlateau yöntemi, modelin doğruluk oranı artışının belirli bir şart sonrasında durduğunu belirleyerek, öğrenme hızını otomatik olarak azaltır. Bu, modelin daha stabil bir şekilde eğitilmesini sağlar ve daha iyi sonuçlar elde etmeye yardımcı olur.

Checkpoint yöntemi ise, her bir eğitim epoch'u sonunda modelin ağırlıklarını ve diğer parametrelerini kaydederek, en iyi modelin belirlenmesini ve kaydedilmesini sağlar. Böylece, eğitim sırasında herhangi bir aksaklık veya kesinti durumunda en son başarılı modelin geri yüklenebilmesini sağlar.

Bu callback'ler, modelin eğitim sürecini daha güvenilir hale getirir ve daha iyi sonuçlar elde etmek için önemli bir rol oynar.

Eğitim ve Değerlendirme

Model, eğitim verileri üzerinde eğitilecek ve doğrulama verileri üzerinde performansı değerlendirilecektir. Eğitim sürecinde, doğruluk (accuracy) ve kayıp (loss) metrikleri takip edilerek modelin gelişimi izlenecektir. Eğitim tamamlandıktan sonra, model test verileri üzerinde değerlendirilecek ve konfüzyon matrisi ile performansı raporlanacaktır.

Sonuç olarak, bu çalışmanın amacı, ISIC 2019 veri seti üzerinde dört deri kanseri sınıfını en yüksek doğruluk oranı ile sınıflandıracak bir derin öğrenme modeli geliştirmektir. Modelin performansını artırmak amacıyla veri genişletme, batch normalization ve dropout gibi yöntemler kullanılacak ve hiperparametre optimizasyonu gerçekleştirilecektir. Elde edilen sonuçlar, literatürdeki mevcut çalışmalarla karşılaştırılarak modelin etkinliği değerlendirilecektir.

4. Deneyler ve Sonular

4.1 Veri Seti


Bu alıřmada kullanılan veri seti, ISIC 2019 veri setidir. ISIC (International Skin Imaging Collaboration) 2019 veri seti, deri lezyonlarının sınıflandırılması amacıyla geniş ve eřitli görüntüler içermektedir. Veri seti, toplamda 25,331 görüntü ve dokuz farklı hastalık sınıfı içermektedir. Tablo 1, her sınıftaki görüntü sayısını ve sınıf ağırlıklarını özetlemektedir.

Sınıf	Görüntü Sayısı
AK	867
BCC	3323
BKL	2624
DF	239
NV	12875
MEL	4522
SCC	628
VASC	253
Toplam	25331

Tablo 1: ISIC 2019 Veri Setinin Genel Görünümü ve Her Sınıftaki Görüntü Sayısı (1)

Veri setindeki sınıflar řunlardır:

- AK (Actinic Keratosis)
- BCC (Basal Cell Carcinoma)
- BKL (Benign Keratosis-like Lesions)
- DF (Dermatofibroma)
- NV (Melanocytic Nevi)
- MEL (Melanoma)
- SCC (Squamous Cell Carcinoma)
- VASC (Vascular Lesions)



Resim 3: Verisetine Ait Bazı Görüntü Örnekleri (2)

Bu çalışmada, veri setinde yeterli sayıda görüntü bulunan dört sınıf (BCC, BKL, MEL ve NV) kullanılarak bir model eğitilecektir. Seçilen sınıflar, her biri için 2000'den fazla görüntü içermektedir, bu da dengeli bir veri seti oluşturarak modelin performansını artırmayı hedeflemektedir.

4.2 Deneysel Yöntemler ve Sonuçlar

Bu aşamada, modelin geliştirilmesi ve performansının değerlendirilmesi için çeşitli deneyler yapılmıştır. İlk olarak, veri genişletme (data augmentation) teknikleri uygulanmış ve ardından modelin mimarisi ve hiperparametreleri optimize edilmiştir. Modelin doğruluk (accuracy) ve kayıp (loss) metrikleri takip edilerek en iyi performans gösteren model belirlenmiştir.

4.2.1 Veri Genişletme (Data Augmentation)

Veri genişletme (data augmentation), derin öğrenme modellerinin eğitiminde kullanılan önemli bir tekniktir. Özellikle sınırlı sayıda eğitim verisi olduğunda, veri genişletme yöntemleri kullanılarak mevcut veri seti artırılır ve modelin genelleme yeteneği geliştirilir. Bu çalışmada da veri genişletme yöntemleri kullanılarak modelin performansının artırılması hedeflenmiştir.

Veri genişletme teknikleri, eğitim verileri üzerinde çeşitli dönüşümler uygulanarak yeni veri örnekleri oluşturulmasını sağlar. Bu dönüşümler, görüntülerin orijinal bilgilerini bozmadan farklı varyasyonlarını oluşturur. Bu sayede, model farklı durumlarla karşılaştığında daha iyi genelleme yapabilir. Bu çalışmada kullanılan veri genişletme yöntemleri şunlardır:

- Döndürme (Rotation): Görüntüler belirli açılarla döndürülerek farklı açılardan görünüm oluşturulur.
- Yatay ve Dikey Çevirme (Horizontal and Vertical Flip): Görüntüler yatay ve dikey olarak çevrilerek simetrik varyasyonlar elde edilir.
- Yakınlaştırma (Zooming): Görüntüler belirli oranlarda yakınlaştırılarak detaylı görünüm elde edilir.
- Parlaklık ve Kontrast Ayarlamaları (Brightness and Contrast Adjustments): Görüntülerin parlaklık ve kontrast değerleri değiştirilerek farklı aydınlatma koşulları simüle edilir.
- Kaydırma (Shifting): Görüntüler yatay ve dikey eksenlerde belirli oranlarda kaydırılarak farklı konumlandırmalar elde edilir.
- Gürültü Ekleme (Adding Noise): Görüntülere rastgele gürültü eklenerek daha zorlu koşullarda modelin performansı artırılır.

Bu veri genişletme teknikleri, eğitim verilerinin çeşitliliğini artırarak modelin daha sağlam ve genelleme yeteneği yüksek olmasını sağlar. Uygulanan veri genişletme yöntemleri, TensorFlow ve Keras kütüphanelerinin sunduğu fonksiyonlar kullanılarak gerçekleştirilmiştir. Örneğin, ImageDataGenerator sınıfı kullanılarak veri genişletme işlemleri kolaylıkla yapılabilir:

Bu veri genişletme yöntemleri sayesinde, eğitim setinin boyutu artırılarak modelin aşırı öğrenme (overfitting) yapması engellenmiş ve modelin genelleme yeteneği artırılmıştır. Veri genişletme, bu çalışmanın önemli bir parçasını oluşturarak, modelin performansını ve doğruluğunu önemli ölçüde iyileştirmiştir.

4.2.2 Genel Model Yapısı

Bu çalışmada kullanılan temel model yapısı, evrişimli sinir ağları (CNN) üzerine kuruludur. CNN modelleri, görüntü işleme ve sınıflandırma görevlerinde oldukça etkilidir. Modelin yapısında kullanılan temel katmanlar ve fonksiyonlar şunlardır:

- Conv2D: İki boyutlu evrişim katmanları, görüntülerin yerel özelliklerini öğrenir.
- GlobalAveragePooling2D: Çok boyutlu çıktıları tek boyutlu bir vektöre dönüştürür.
- Dense: Tam bağlantılı katmanlar, sınıflandırma işlemini gerçekleştirir.
- Aktivasyon Fonksiyonu: Her katmanda relu (Rectified Linear Unit) aktivasyon fonksiyonu kullanılırken, son katmanda softmax aktivasyon fonksiyonu kullanılarak sınıf olasılıkları hesaplanır.
- Optimizer: Modelin optimizasyonu için adam optimizasyon algoritması kullanılır.

Bu yapı, görüntülerin özelliklerini öğrenmek ve sınıflandırma görevini yerine getirmek için katmanlar arasında sıralı bir bağlantı kurar.

4.2.3 Max Pooling

Max Pooling, evrişimli sinir ağlarında yaygın olarak kullanılan bir tekniktir. Bu teknik, görüntülerdeki özelliklerin boyutunu küçültmek ve hesapsal yükü azaltmak için kullanılır. Max Pooling, belirli bir havuzlama penceresi içindeki maksimum değeri seçerek, veri boyutunu azaltır ve en belirgin özellikleri korur. Bu yöntem, modelin hesaplama verimliliğini artırır ve aşırı öğrenmeyi (overfitting) azaltır.

4.2.4 Batch Normalization

Batch Normalization, derin sinir ağlarının eğitim sürecini hızlandırmak ve kararlılığını artırmak için kullanılan bir tekniktir. Bu yöntem, her mini-batch'in ortalama ve standart sapmasını kullanarak katmanların çıkışlarını normalleştirir. Batch Normalization, modelin aşırı öğrenmesini azaltabilir ve daha iyi genelleme yapmasını sağlayabilir. Ayrıca, modelin öğrenme sürecini hızlandırarak daha hızlı bir şekilde sonuca ulaşmasını sağlar.

4.2.5 Dropout

Dropout, sinir ağlarının aşırı öğrenmesini engellemek için kullanılan bir tekniktir. Bu yöntem, her eğitim adımında belirli bir oranda nöronu rastgele devre dışı bırakır, böylece modelin belirli nöronlara bağımlı hale gelmesi önlenir ve modelin genelleme yeteneği artırılır. Dropout, özellikle tam bağlantılı katmanlarda kullanılarak, modelin aşırı öğrenmesini önlemeye yardımcı olur ve daha sağlam bir öğrenme süreci sağlar.

Bu yöntemler, modelin performansını ve genelleme yeteneğini artırmak için birlikte kullanılır. Her bir yöntem, modelin belirli bir yönünü optimize ederek daha yüksek doğruluk ve kararlılık elde edilmesini sağlar. Bu kombinasyon, verimli ve etkili bir derin öğrenme modeli oluşturmak için temel yapı taşlarını oluşturur.

4.3 Model Karşılaştırmaları ve Sonuçlar

Bu bölümde, çeşitli model yapılarını kullanarak gerçekleştirdiğimiz deneylerin sonuçlarını inceleyeceğiz. Her modelde, farklı mimari değişiklikler, hiperparametre ayarlamaları ve eğitim stratejileri uygulanarak en yüksek doğruluğa ulaşmak hedeflenmiştir. Model mimarileri, derinleştirilip karmaşık hale getirildiği gibi, sadeleştirilip daha az katmanlı hale de getirilmiştir. Bu denemeler sonucunda, elde edilen doğruluk, eğitim ve doğrulama kayıpları karşılaştırılarak en başarılı model seçilmiştir.


Denemeler süresince aşağıdaki adımlar izlenmiştir:

- **Model Mimarisinin Değiştirilmesi:** Farklı derinlik ve karmaşıklık seviyelerinde modeller tasarlandı. Bu modellerde Conv2D, Max Pooling, Batch Normalization ve Dropout gibi katmanlar kullanıldı. Bazı modeller daha derin yapılar kullanırken, diğerleri daha az katmanla sadeleştirildi.
- **Hiperparametre Ayarlamaları:** Öğrenme oranı, batch boyutu, epoch sayısı gibi hiperparametreler üzerinde çeşitli ayarlamalar yapıldı. Bu ayarlamaların model performansına etkileri incelendi.
- **Data Augmentation:** Veri artırma teknikleri kullanılarak, modelin genelleme yeteneği artırıldı ve overfitting azaltıldı.


Sonuç olarak, doğruluk oranı %74 olan en başarılı model elde edilmiştir. Bu modelin performansını daha iyi anlamak için konfüzyon matrisi, train ve validation loss ile accuracy grafiklerini çıkardık. Bu grafikler, modelin eğitim sürecinde nasıl bir performans gösterdiğini ve validation setinde nasıl genelleme yaptığını görselleştirmektedir.

Aşağıda, bu sonuçları özetleyen grafik ve tablolar bulunmaktadır:

- **Konfüzyon Matrisi:** Modelin sınıflandırma performansını detaylı bir şekilde gösterir. Her sınıf için doğru ve yanlış sınıflandırmaların sayısını içerir.
- **Train ve Validation Loss Grafikleri:** Modelin eğitim sürecindeki kayıp değerlerinin epochlara göre değişimini gösterir. Eğitim ve doğrulama kayıplarının birbirine yakın olması, modelin iyi genelleme yaptığını gösterir.
- **Train ve Validation Accuracy Grafikleri:** Modelin eğitim sürecindeki doğruluk oranlarının epochlara göre değişimini gösterir. Yüksek doğruluk oranları, modelin sınıflandırma görevini başarıyla yerine getirdiğini belirtir.



Resim 4: En Başarılı Modelin Accuracy ve Loss Grafiği



Resim 5: En Başarılı Modelin Test Sonuçları İçin Konfüzyon Matrisi

Bu görseller, modelin performansını ve eğitim sürecini görsel olarak anlamamıza yardımcı olacaktır. En başarılı modelin özellikleri, hiperparametre ayarları ve mimari yapısı detaylandırılarak, bu sonuçların diğer çalışmalarla karşılaştırılması yapılacaktır. Bu süreç, optimal bir modelin nasıl geliştirilebileceği konusunda önemli bilgiler sunacaktır.

5. Sonuç

Bu çalışma, deri kanseri teşhisinde derin öğrenme yöntemlerinin kullanılabilirliğini araştırmak amacıyla yapılmıştır. Deri kanseri teşhisinde doğru ve hızlı bir sınıflandırma modeli geliştirmek için ISIC 2019 veri seti kullanılarak bir derin öğrenme modeli oluşturulmuştur. Modelin geliştirilmesi için belirlenen dört deri kanseri sınıfı (BCC, BKL, MEL ve NV) üzerinde yoğunlaşmış ve veri setinin dengelenmesi için gerekli önlemler alınmıştır.

Çalışmada, modelin eğitiminde ve değerlendirilmesinde çeşitli teknikler ve yöntemler kullanılmıştır. Bu teknikler arasında veri genişletme, hiperparametre optimizasyonu ve callback'ler gibi yöntemler bulunmaktadır. Ayrıca, modelin performansını değerlendirmek için literatürdeki benzer çalışmalarla karşılaştırma yapılmıştır.

Elde edilen sonuçlar, geliştirilen modelin deri kanseri sınıflandırma görevinde etkili olduğunu göstermektedir. Modelin yüksek doğruluk oranları ve güvenilirliği, derin öğrenme tekniklerinin deri kanseri teşhisinde kullanımının potansiyelini vurgulamaktadır.

Sonuç olarak, bu çalışma, deri kanseri teşhisinde derin öğrenme modellerinin kullanılabilirliğini ve etkinliğini göstermektedir. Gelecekte, daha geniş veri setleri ve daha karmaşık modellerle yapılan çalışmaların bu alandaki ilerlemeyi daha da ileriye taşıması beklenmektedir.

Kaynakça:

- 1: https://www.researchgate.net/publication/365804093_Multiclass_skin_lesion_classification_in_dermoscopic_images_using_swin_transformer_model
- 2: <https://www.kaggle.com/datasets/andrewmvd/isic-2019/data>
- 3: <https://www.kaggle.com/code/ashfakyeafi/isic-2019/notebook>
- 4: <https://www.chatgpt.com>